

미션 16 요약 보고서

모델 포맷 변환 및 ONNX 추론 검증

팀/이름: 1팀 안호성

기본 모델: qtranslator_1.7b_v2

제출 산출물: modeling.ipynb, inference.ipynb, 요약보고서 PDF, 용량

이미지, 디버깅 기록

실험 목적: .pth / 양자화 .pth / .onnx 변환 및 형식별 추론 검증

핵심 요약

- 양자화 PTH 용량은 2828.51MB로 원본 PTH(6563.60MB)보다 작았다.
- ONNX는 .onnx와 .onnx.data를 합산해야 실제 용량(6568.74MB)이다.
- CPU 기준 평균 추론 시간은 pth_quant 0.8936초, onnx 3.3624초였다.
- 다만 ONNX는 KV cache 없는 수동 greedy decoding 구현이라 시간상 불리하다.

1. 실험 개요

- 학습된 qtranslator_1.7b_v2 모델을 PyTorch 기본 형식(.pth), 동적 양자화 .pth, ONNX 형식으로 변환했다.
- 변환 후 Hugging Face 원본 모델, .pth, 양자화 .pth, ONNX가 동일 번역 프롬프트에서 추론 가능한지 검증했다.
- 시간 비교의 일관성을 위해 inference 실험은 모든 방식을 CPU 기준으로 통일했다.

2. 모델 추출 결과

- 저장 파일명 규칙은 과제 요구사항에 맞춰 mission_16_{model_name}.pth / .onnx 형식을 사용했다.
- ONNX는 대용량 가중치를 external data(.onnx.data)로 분리 저장했다.

형식	파일명	용량(MB)
PTH	mission_16_qtranslator_1.7b_v2.pth	6563.60
PTH Quantized	mission_16_qtranslator_1.7b_v2_quantized.pth	2828.51
ONNX + external	mission_16_qtranslator_1.7b_v2.onnx + .onnx.data	6568.74

3. 추론 결과

방식	avg_sec	min_sec	max_sec
pth_quant	0.8936	0.587	1.109
pth	1.8774	1.263	2.627
hf	1.9756	1.257	2.523
onnx	3.3624	1.885	5.333

4. 결과 해석

- 이번 실험에서는 pth_quant가 가장 빨랐고, onnx가 가장 느리게 측정되었다.
- 그러나 이것을 곧바로 ONNX 포맷 자체의 절대적인 성능 열세로 해석하면 안 된다.
- 현재 ONNX 추론 코드는 onnxruntime 세션을 직접 호출하는 수동 greedy decoding 방식이며, past_key_values(KV cache)를 사용하지 않는다.
- 따라서 새 토큰을 생성할 때마다 전체 시퀀스를 다시 계산하게 되어 Hugging Face generate 경로보다 시간상 불리하다.
- 또한 contains_ref는 정답 문장이 예측에 문자열 그대로 포함되는지만 확인하는 단순 지표라, 의미가 유사해도 0으로 집계될 수 있다.

5. 디버깅 및 오류 해결

- ONNX export 시 opset 17 변환 단계에서 경고가 발생했으나, 파일 저장이 완료되어 Runtime 추론으로 유효성을 확인했다.
- 대용량 external-data ONNX를 onnx.checker.check_model(onnx_model)로 검사할 때 EncodeError가 발생해, 경로 기반 검사(check_model(model_path))로 수정했다.
- ONNX 본체만 보면 파일 크기가 작아 보였으나, 실제 가중치는 .onnx.data에 저장되어 있어 합산 용량으로 계산하도록 변경했다.

6. 결론

- 세 가지 형식(.pth, 양자화 .pth, .onnx)으로 모델 저장에 성공했다.
- Hugging Face 원본 모델, .pth, 양자화 .pth, ONNX 모두 추론 가능함을 확인했다.
- 용량 측면에서는 양자화 PTH가 가장 유리했다.
- 시간 비교는 CPU 기준으로 통일했으며, ONNX 결과는 현재 구현 제약을 포함한 결과로 해석해야 한다.

부록 A. 모델 용량 비교 이미지



